

Fine-Tuning e Destilação do BERT-tiny para Português (BERT-tiny-PT)

Pedro Rebollo e Tatiane Correia

01 Dezembro 2025

Abstract

This project investigates the possibility of adapting the BERT-tiny model to Brazilian Portuguese using knowledge distillation techniques. The main goal is to produce a lightweight, efficient model capable of understanding Portuguese, while preserving part of the representational capacity of a much larger teacher model, BERTimbau-base. To this end, two approaches were explored: partial distillation, which preserves the student's original tokenizer, and full distillation, which completely replaces the student's vocabulary with that of the teacher. The experiments show that the resulting model, named BERT-tiny-PT, does in fact learn the basic patterns of the Portuguese language, with a substantial improvement in Masked Language Modeling. In downstream tasks of a semantic nature, evaluated both intrinsically (textual similarity) and with supervised fine-tuning on smaller sentiment and entailment datasets, the students' performance remains below that of the teacher, reinforcing that distillation alone does not replace deeper task-specific supervised tuning.

1 Introdução

Modelos de linguagem de grande porte apresentam desempenho excepcional em tarefas de compreensão textual, porém com altos custos computacionais, tornando difícil sua utilização em cenários restritos em memória, latência e recursos. Uma solução bastante adotada é a destilação de conhecimento, na qual um modelo grande (teacher) transfere parte de sua capacidade para um modelo menor (student), que se torna mais rápido e eficiente, preservando parte do poder expressivo.

Neste projeto, buscamos adaptar o modelo BERT-tiny, originalmente treinado apenas em inglês, para o português brasileiro. Para isso, utilizamos o modelo BERTimbau-base como professor, devido à sua robusta capacidade e ao seu amplo vocabulário treinado em textos do português. A pergunta que guiou todo o desenvolvimento foi se seria possível construir um modelo extremamente pequeno, rápido e economicamente viável, mas com capacidade de compreender textos em português de forma útil. Ao longo do projeto, construímos dois caminhos experimentais: a destilação parcial, que mantém o vocabulário do aluno, e a destilação total, que faz o aluno adotar integralmente o tokenizador e o vocabulário do professor. Além da avaliação intrínseca em Masked Language Modeling, investigamos também tarefas downstream de natureza semântica, combinando avaliação baseada apenas em embeddings com fine tuning supervisionado em tarefas de classificação.

2 Metodologia

A metodologia utilizada baseou-se nos princípios clássicos de destilação, com rápidas iterações experimentais. Inicialmente, foram consideradas duas estratégias distintas. Na destilação parcial, mantivemos o tokenizador original do BERT-tiny, que é baseado em inglês. O professor, BERTimbau-base, fornecia os embeddings de referência, e o aluno aprendia por meio de dois componentes de perda: Masked Language Modeling e similaridade de cosseno entre embeddings do professor e do aluno.

Na destilação total, adotamos uma abordagem mais fiel ao que é recomendado na literatura. O aluno foi reconstruído do zero, preservando apenas a arquitetura compacta do BERT-tiny, mas substituindo completamente seu vocabulário pelo do professor. O tokenizador passou a ser o mesmo do BERTimbau. Como a dimensão do embedding do professor (768) e a do aluno (128) são diferentes, adicionamos ao aluno uma camada linear de projeção para que as representações do professor pudessem ser aproximadas pelo espaço vetorial reduzido do aluno. Essa técnica possibilita que o aluno aprenda de forma muito mais compatível com o professor.

Após definir a arquitetura, combinamos as três perdas (MLM, KD e Cosine) com pesos específicos e treinamos o modelo por três épocas completas no corpus limpo. O treinamento foi conduzido utilizando GPUs de alto desempenho, permitindo que milhões de sentenças fossem processadas.

Para avaliação, seguimos dois eixos complementares. No eixo intrínseco, utilizamos Masked Language Modeling no conjunto de teste do brWaC e Similaridade Textual (ASSIN2 – STS), com embeddings obtidos por mean pooling das últimas camadas e correlação de Pearson entre a similaridade de cosseno e os escores de similaridade humana. No eixo extrínseco, avaliamos Análise de Sentimentos (TweetSentBR) e Reconhecimento de Entailment Textual (ASSIN2 – RTE) com fine tuning supervisionado: para cada modelo, acoplamos uma cabeça de classificação e treinamos por algumas épocas nos respectivos conjuntos de treinamento, avaliando em seguida nos conjuntos de teste ou validação oficiais de cada corpus.

3 Dados

Para realizar a destilação, utilizamos o corpus brWaC, composto por mais de 3,5 milhões de textos de páginas brasileiras da web. Por ser um dataset ruidoso, realizamos uma etapa rigorosa de pré-processamento. Removemos HTML, URLs, metadados, repetições e entradas extremamente curtas ou extremamente longas. Após essa limpeza, o conjunto foi reduzido para aproximadamente 3,25 milhões de textos, preservando apenas aqueles com conteúdo linguístico relevante.

Esse corpus foi então dividido em 90 por cento para treinamento e 10 por cento para teste, formando a base para avaliar a capacidade do modelo em prever tokens mascarados em sentenças nunca vistas. A diversidade temática e a quantidade massiva de dados tornaram o brWaC ideal para treinar um modelo destinado a compreender português de forma geral.

Para avaliação extrínseca, utilizamos três benchmarks em português: o TweetSentBR Few-shot, para Análise de Sentimentos; o ASSIN2 na configuração de Similaridade Textual (STS), com escores contínuos de similaridade; e o ASSIN2 na configuração de Reconhecimento de Entailment Textual (RTE), com rótulos de entailment, contradição e neutro.

4 Experimentos

Os experimentos foram conduzidos separadamente para as abordagens de destilação parcial e total, aplicadas sobre o corpus brWaC previamente limpo e dividido em 90 por cento para treino e 10 por cento para teste. O objetivo desta seção é comparar o desempenho dos modelos em tarefas de avaliação intrínseca e extrínseca, buscando entender como cada estratégia impacta o aprendizado linguístico e semântico do estudante.

4.1 Destilação parcial

Na destilação parcial, preservamos o tokenizador e o vocabulário originais do BERT-tiny em inglês, bem como seus pesos iniciais. O professor forneceu apenas representações internas, e o aluno foi treinado combinando Masked Language Modeling com similaridade de cosseno. Apesar do desalinhamento entre vocabulários, o modelo parcialmente destilado apresentou bom desempenho em MLM, alcançando perda de 2,1547, valor relativamente próximo ao do professor (1,7577) e substancialmente melhor que o tiny original em inglês (5,7138). Isso indica que, mesmo com tokenização baseada em inglês, o estudante consegue capturar padrões básicos da língua portuguesa.

Em Similaridade Textual (ASSIN2 – STS), medindo a correlação de Pearson entre a similaridade de cosseno dos embeddings e os escores humanos, o modelo parcialmente destilado atingiu 0,5763, superando o tiny original (0,5262) e aproximando-se do professor (0,6139). Esses resultados sugerem que parte da estrutura semântica global foi preservada nas representações aprendidas pelo estudante parcial.

Nas tarefas de classificação com fine tuning supervisionado, observamos um cenário mais desafiador. Em Análise de Sentimentos (TweetSentBR), após treinar uma cabeça de classificação sobre o encoder de cada modelo, o estudante parcial obteve F1 de 0,1905, inferior ao tiny original em inglês (0,3583) e ao BERTimbau-base (0,9360), e acima apenas do estudante totalmente destilado. Já na tarefa de entailment (ASSIN2 – RTE), com fine tuning supervisionado na tarefa de inferência textual, o modelo parcialmente destilado alcançou F1 de 0,6334, desempenho melhor que o estudante totalmente destilado (0,6036), mas ainda abaixo do tiny original em inglês (0,6675) e, como esperado, do professor BERTimbau-base (0,9360).

De forma geral, na configuração de destilação parcial, o estudante aproxima-se mais do professor em métricas intrínsecas, como MLM e STS, mas ainda apresenta um hiato significativo em tarefas de classificação supervisionada, especialmente quando comparado ao teacher e ao tiny original em inglês.

4.2 Destilação total

Na destilação total, reconstruímos o aluno adotando o tokenizador e o vocabulário do BERTimbau-base, adicionando uma camada de projeção para compatibilizar as dimensões de embedding. Nesse processo, utilizamos perdas de MLM, divergência KL com temperatura 2,0 e similaridade de cosseno. O modelo totalmente destilado apresentou perda de MLM de 3,9649, melhor que o tiny original (5,7138), mas inferior ao modelo parcialmente destilado e mais distante do professor. Em Similaridade Textual, atingiu Pearson de 0,4400, valor inferior ao tiny original e ao professor, refletindo que, embora o vocabulário esteja totalmente alinhado ao português, o espaço semântico ainda precisa ser reforçado com mais treinamento.

Nas tarefas de classificação com fine tuning, o modelo totalmente destilado obteve F1 de 0,0833 em Análise de Sentimentos, desempenho próximo ao nível aleatório e inferior aos demais modelos avaliados. Em entailment (ASSIN2 – RTE), alcançou F1 de 0,6036, ficando abaixo tanto do estudante parcial quanto do tiny original, mas ainda capturando parte da estrutura da tarefa após o treinamento supervisionado.

Assim, a destilação total produz um modelo mais alinhado ao português do ponto de vista morfosintático, mas com semântica ainda limitada, tanto nas métricas intrínsecas quanto nas tarefas supervisionadas. Os resultados sugerem que, nessa configuração, seriam necessárias mais épocas de treinamento em MLM e possivelmente estratégias adicionais para fortalecer o espaço de representações antes de esperar desempenho competitivo nas tarefas downstream.

4.3 Comparação geral

Comparando todas as métricas de forma conjunta, observamos que:

- Em MLM e STS, o BERTimbau-base permanece como melhor modelo, com os estudantes destilados aproximando-se dele em graus diferentes, e o tiny original em inglês ficando consistentemente atrás nas métricas intrínsecas.
- Em Análise de Sentimentos e RTE com fine tuning, o professor continua com larga vantagem, e o tiny original em inglês geralmente supera os estudantes destilados, refletindo o impacto de um pré-treinamento longo e estável, mesmo em outro idioma.
- Entre os estudantes, a destilação parcial tende a produzir melhores representações semânticas que a destilação total nas métricas avaliadas, embora nenhum dos dois atinja o desempenho do professor nas tarefas supervisionadas.

Do ponto de vista de eficiência, os modelos BERT-tiny-PT mantêm aproximadamente 4,3 milhões de parâmetros, com tamanhos em torno de 16 a 17 MB, contra cerca de 109 milhões de parâmetros e mais de 400 MB do BERTimbau-base. A destilação, portanto, produz modelos muito mais leves, ao custo de desempenho semântico ainda distante do teacher.

Observação metodológica

Ao longo do desenvolvimento, realizamos inicialmente algumas avaliações exploratórias em TweetSentBR e ASSIN2 – RTE sem ajuste supervisionado, acoplando cabeças de classificação recém-inicializadas diretamente aos encoders pré-treinados. Esses resultados preliminares, em regime de zero shot, foram úteis para entender qualitativamente o comportamento das representações, mas não são os valores que utilizamos como base para as conclusões finais deste relatório. As métricas reportadas e discutidas na seção de Experimentos para sentimento e entailment correspondem à configuração com fine tuning supervisionado das cabeças de classificação, que é o cenário mais alinhado à prática usual de avaliação em tarefas downstream. O repositório se encontra disponível [aqui](#)

5 Conclusão

O BERT-tiny-PT alcançou os objetivos essenciais do projeto: tornou-se capaz de compreender o idioma português em nível lexical e sintático e apresentou desempenho superior ao modelo original em inglês em Masked Language Modeling, além de melhorar as representações em Similaridade Textual em relação ao tiny original. Ainda assim, a transferência completa da capacidade semântica não ocorreu. As análises demonstram que a destilação, embora eficaz na transferência de conhecimento superficial e na melhoria da modelagem de linguagem, não é suficiente, sozinha, para garantir desempenho satisfatório em tarefas que exigem raciocínio semântico mais complexo.

Mesmo após realizar fine tuning supervisionado em conjuntos menores de Análise de Sentimentos e Entailment, os estudantes destilados permanecem bem abaixo do professor nessas tarefas.

6 Trabalhos futuros

Como continuação natural deste projeto, alguns caminhos de aprimoramento se destacam. Em primeiro lugar, seria importante aumentar o tempo de treinamento em MLM, especialmente na configuração de destilação total, para reforçar o espaço semântico antes do fine tuning supervisionado. Outro passo relevante seria experimentar variações de destilação, como o uso de camadas intermediárias do professor ou diferentes combinações de funções de perda. Também pretendemos ampliar a avaliação extrínseca, incluindo mais tarefas e conjuntos de dados em português.

Referências

- [1] Jiao et al. (2020) – TinyBERT: Distilling BERT for Natural Language Understanding.
- [2] Sanh, Victor, et al. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108 (2019).

- [3] Souza et al. (2020) – BERTimbau: Pretrained BERT Models for Brazilian Portuguese.
- [4] Wagner et al. (2018) – The brWaC Corpus: A New Open Resource for Brazilian Portuguese.